Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ Информатика и системы управления
КАФЕДРА Системы обработки информации и управления

Рубежный контроль №2
«Методы построения моделей машинного обучения»
по курсу «Технологии машинного обучения»

Вариант №26

Выполнил:
Студент группы ИУ5Ц-81Б
Булыгина С.А.

Проверил:
Преподаватель кафедры ИУ5
Гапанюк Ю.Е.

Москва 2021

Данные варианта:

Номер варианта	Метод №1	Метод №2
26	Линейная/ логистическая регрессия	Случайный лес

Задача:

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Набор данных: https://www.kaggle.com/brsdincer/star-type-classification

Выполнение рубежного контроля:

**РК2 Булыгина С.А. ИУ5Ц-81Б **

Импорт библиотек

In [1]:
```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from pandas.plotting import scatter_matrix
import warnings
warnings.filterwarnings('ignore')
sns.set(style="ticks")
%matplotlib inline
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from sklearn.metrics import mean_absolute_error, mean_squared_error,  median_absolute_error, r2_score
```

In [2]:
```
data = pd.read_csv('Stars.csv')
```

In [3]:
```
data.head()
```

Out[3]:

	Temperature	L	R	A_M	Color	Spectral_Class	Type
0	3068	0.002400	0.1700	16.12	Red	M	0
1	3042	0.000500	0.1542	16.60	Red	M	0
2	2600	0.000300	0.1020	18.70	Red	M	0
3	2800	0.000200	0.1600	16.65	Red	M	0
4	1939	0.000138	0.1030	20.06	Red	M	0

In [4]:
```
data['R'] = data['R'].astype(int)
data['L'] = data['L'].astype(int)
le = LabelEncoder()
le.fit(data.Color.drop_duplicates())
data.Color = le.transform(data.Color)
le = LabelEncoder()
le.fit(data.Spectral_Class.drop_duplicates())
data.Spectral_Class = le.transform(data.Spectral_Class)
```

In [5]:
```
data.head()
```

Out[5]:

	Temperature	L	R	A_M	Color	Spectral_Class	Type
0	3068	0	0	16.12	8	5	0
1	3042	0	0	16.60	8	5	0
2	2600	0	0	18.70	8	5	0
3	2800	0	0	16.65	8	5	0
4	1939	0	0	20.06	8	5	0

In [6]:
```
data = data.fillna(1)
```

In [7]:
```
data.dtypes
```

Out[7]:
```
Temperature         int64
L                   int32
R                   int32
A_M               float64
Color               int32
Spectral_Class      int32
Type                int64
dtype: object
```

In [8]:
```
data.isnull().sum()
```

Out[8]:
```
Temperature       0
L                 0
R                 0
A_M               0
Color             0
Spectral_Class    0
Type              0
dtype: int64
```

In [9]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 240 entries, 0 to 239
Data columns (total 7 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   Temperature     240 non-null    int64
 1   L               240 non-null    int32
 2   R               240 non-null    int32
 3   A_M             240 non-null    float64
 4   Color           240 non-null    int32
 5   Spectral_Class  240 non-null    int32
 6   Type            240 non-null    int64
dtypes: float64(1), int32(4), int64(2)
memory usage: 9.4 KB
```

In [10]:
```
data.head()
```

Out[10]:

	Temperature	L	R	A_M	Color	Spectral_Class	Type
0	3068	0	0	16.12	8	5	0
1	3042	0	0	16.60	8	5	0
2	2600	0	0	18.70	8	5	0
3	2800	0	0	16.65	8	5	0
4	1939	0	0	20.06	8	5	0

In [11]:
```
parts = np.split(data, [1,17,18], axis=1)
X = parts[0]
Y = parts[1]
G = parts[2]
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', G.head())
```

```
Входные данные:

    Temperature
0       3068.0
1       3042.0
2       2600.0
3       2800.0
4       1939.0

Выходные данные:

 Empty DataFrame
Columns: []
Index: [0, 1, 2, 3, 4]
```

In [12]:
```
#Построим корреляционную матрицу
fig, ax = plt.subplots(figsize=(15,7))
sns.heatmap(data.corr(method='pearson'), ax=ax, annot=True, fmt='.2f')
```

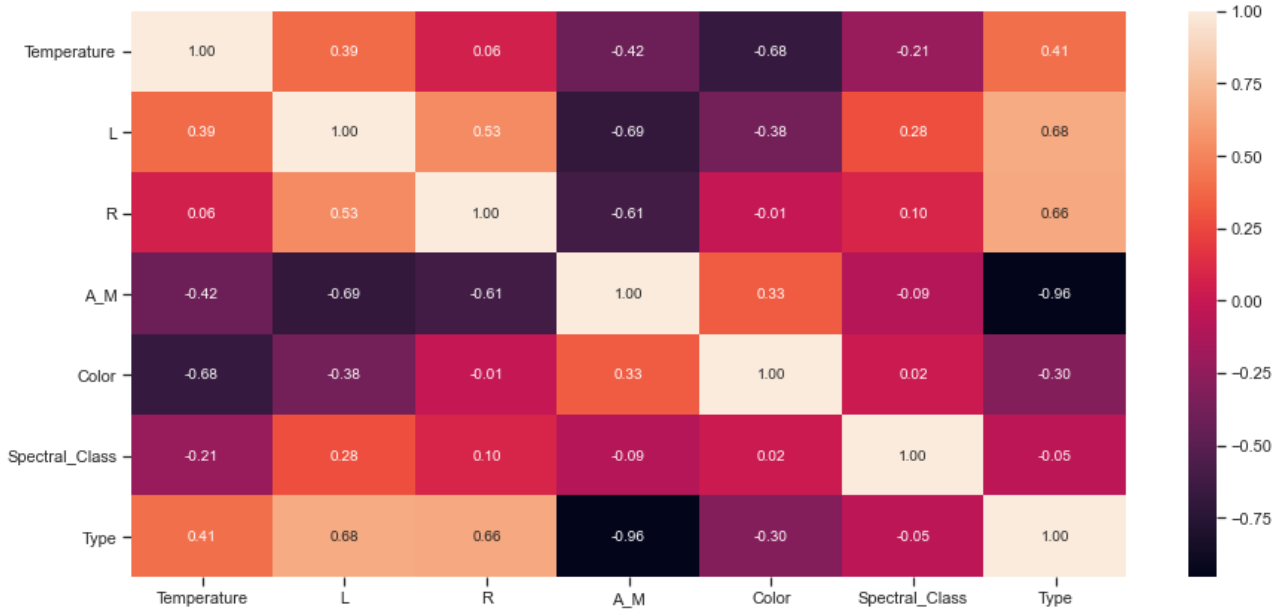

In [13]:

In [13]:
```
X = data.drop(['R','Color','Spectral_Class','L','R', 'Type','Temperature'], axis = 1)
Y = data.Type
print('Входные данные:\n\n', X.head(), '\n\nВыходные данные:\n\n', Y.head())
```

```
Входные данные:

      A_M
0  16.12
1  16.60
2  18.70
3  16.65
4  20.06

Выходные данные:

 0    0
1    0
2    0
3    0
4    0
Name: Type, dtype: int64
```

In [14]:
```
X_train,  X_test,  Y_train,  Y_test = train_test_split(X,  Y, random_state = 0, test_size = 0.1)
print('Входные параметры обучающей выборки:\n\n',X_train.head(), \
      '\n\nВходные параметры тестовой выборки:\n\n', X_test.head(), \
      '\n\nВыходные параметры обучающей выборки:\n\n', Y_train.head(), \
      '\n\nВыходные параметры тестовой выборки:\n\n', Y_test.head())
```

```
Входные параметры обучающей выборки:

        A_M
5    16.980
22   14.230
199  14.776
97    2.440
12   13.210

Входные параметры тестовой выборки:

        A_M
109  -5.79
71   10.12
37    2.93
74   10.89
108  -6.24

Выходные параметры обучающей выборки:

 5      0
22     2
199    1
97     3
12     1
Name: Type, dtype: int64

Выходные параметры тестовой выборки:

 109    4
71     1
37     3
74     1
108    4
Name: Type, dtype: int64
```

In [15]:
```
from sklearn.svm import SVC , LinearSVC
```

In [16]:
```
SVC = LinearSVC().fit(X_train, Y_train)
pred_y = SVC.predict(X_test)
```

In [17]:
```
plt.scatter(X_test.A_M, Y_test,    marker = 's', label = 'Тестовая выборка')
plt.scatter(X_test.A_M, pred_y, marker = '.', label = 'Предсказанные данные')
plt.legend (loc = 'lower right')
plt.xlabel ('A_M')
plt.ylabel ('Type')
plt.show()
```

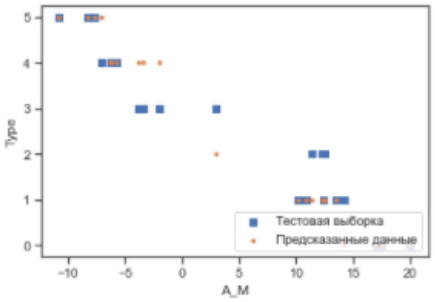

In [18]:
```
from sklearn.ensemble import RandomForestRegressor
```

In [19]:
```
forest_1 = RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
forest_1.fit(X, Y)
```

Out[19]:
```
RandomForestRegressor(n_estimators=5, oob_score=True, random_state=10)
```

In [20]:
```
Y_predict = forest_1.predict(X_test)
print('Средняя абсолютная ошибка:',   mean_absolute_error(Y_test, Y_predict))
print('Средняя квадратичная ошибка:', mean_squared_error(Y_test, Y_predict))
print('Median absolute error:',       median_absolute_error(Y_test, Y_predict))
print('Коэффициент детерминации:',    r2_score(Y_test, Y_predict))
```

```
Средняя абсолютная ошибка: 0.08611111111111112
Средняя квадратичная ошибка: 0.05574074074074076
Median absolute error: 0.0
Коэффициент детерминации: 0.9790426457789382
```

In [21]:
```
plt.scatter(X_test['A_M'], Y_test,    marker = 'o', label = 'Тестовая выборка')
plt.scatter(X_test['A_M'], Y_predict, marker = '.', label = 'Предсказанные данные')
plt.legend(loc = 'lower right')
plt.xlabel('A_M')
plt.ylabel('Type')
plt.show()
```